

Fine tuning de petits LM spécialisés en cybersécurité avec Unsloth & LoRA

... presque aucune expertise en IA nécessaire !

50 Minutes

David Girard

Atelier d'Implémentation d'IA en Cybersécurité
Pour les Professionnels de la Sécurité avec Peu d'Expérience en IA



Avertissements

-Cette présentation n'engage que moi et non mon employeur : Trend Micro

-Je ne suis pas un data scientist ou un AI Engineer, je suis un spécialiste en cybersécurité qui est retourné se former en IA pour pouvoir performer avec une tonne de données de cybersécurité en 2017.

-Si vous êtes un data scientist, cela ne sera pas intéressant pour vous, le public cible ce sont les hackers.

~~-Peut contenir~~ Contient du code




Note: la présentation et le code seront disponibles à la fin sur Github...attendez le QRCode.

Petits concepts LLM clés avant de commencer

- **Open Weight:** Un modèle LLM ou SLM est une matrice de poids (paramètres) d'où l'expression Open Weight au lieu d'Open Source quand le modèle est disponible publiquement
- **Inférence:** c'est l'utilisation d'un LLM pour générer des réponses à partir d'une nouvelle entrée (prompt).
- **Entraînement:** Créer un modèle à partir de zéro sur des immenses datasets
- **Fine Tuning (Affinage):** Complet (FullFT) versus LoRA (Low-Rank Adaptation) ou Parameter Efficient Fine-tuning (PEFT). Le Fine tuning complet (FullFT) ajuste tous les paramètres d'un modèle pré-entraîné pour un maximum de précision tandis que LoRA ne modifie qu'un sous ensemble de paramètres. D'où une grande différence de ressources exigées et de coûts.
- **Quantization:** technique qui réduit la précision des nombres flottants utilisés dans les paramètres des grands modèles de langage afin de diminuer leur consommation de mémoire et accélérer l'inférence.

Précision	Taille par poids	Taille totale pour LLM 8B	Exemple positif	Exemple négatif
FP32	4 bytes	32 Go	0.25 → 0x3f200000	-1.25 → 0xbf200000
FP16	2 bytes	16 Go	0.25 → 0011110000000000	-1.25 → 11000000001010000
INT8	1 byte	8 Go	5 → 00000101	-5 → 11111011
INT4	0.5 byte	4 Go	7 → 0111	-7 → 1001

Pourquoi des petits modèles?




At-a-glance comparison

Model	GPUs	GPU type	Time	Epochs	Compute scale (GPU-days)
Primus-8B	32	H200	≈ 30 h (~1.25 d)	2	≈ 30–40 GPU-days
Primus-70B	32	H100	≈ 175 h (~7 d)	2	≈ 220–250 GPU-days

4. Le cycle de vie en IA générative est extrêmement court. Chaque mois ou plutôt chaque semaine il y a un meilleur modèle. Donc imaginez 8 000\$-14 000\$/3 mois...
5. Plusieurs petits modèles sous les 5B très performants (Gemma, PHI, Qwen..) sont apparus sur le marché ainsi que des outils/techniques comme Unsloth et LoRA (QLoRA).

Pourquoi des petits modèles?

6. L'IA Agentique est la nouvelle sensation et nous voyons plusieurs agents spécialisés coordonnés par un Agent orchestrateur. Donc des petits agents spécialisés qui appellent des petits modèles hyper spécialisés. L'orchestrateur et le juge peuvent utiliser des modèles plus costauds mais le gros du travail sera fait par les petits agents et modèles.
7. Edge AI / Souveraineté / Confidentialité / Contrôle des coûts de l'IA/ Environnement
 - Tous ces facteurs font en sorte que les organisations veulent maintenant héberger l'IA sur leurs équipements (Laptop, Mobile, Serveurs...) et aussi éviter la dépendance à un fournisseur.



Références dans le repo github



Critères pour choisir votre SLM de base?

- Déterminer le matériel qui sera utilisé pour l'inférence (Edge, mobile, Laptop, CPU, NPU, TPU, GPU consommateur, GPU Entreprise) et la VRAM.
- Déterminer le logiciel d'inférence cible : vLLM, LM Studio, Ollama...
- Déterminer les prérequis de la tâche à exécuter : Générer des sommaires, raisonnement, multilinguisme, multimodal (texte, audio, images, vidéos), longueur du contexte.
 - Regardez les résultats de benchmarks pour vous aidez. Ce ne sont que des indicateurs.
 - Sélectionnez au moins deux modèles pour les comparer **avec vos prompts** car les benchmarks sont trop généraux versus votre problème spécifique.
 - Comparez plusieurs niveaux de quantization.



⚠ Défis : Pourquoi les grands modèles sont inaccessibles

Barrières de ressources limitant l'adoption en cybersécurité

📦 Principales barrières d'accessibilité

Exigences Matérielles

- Llama 3.1 70B : 140+ GB VRAM (inférence FP16)
- GPU Entreprise : A100/H100 (80GB) requis Coût : 15k-50k \$ par GPU
- Nous avons utilisés : 32 GPU H100 pour 175 heures
- Accessibilité réduite

Alternative

- Google Colab T4 (~15GB usable) mais Colab Pro (15\$) recommandé
- RTX4070 Ti Super (16GB) : Modèles moyens accessibles
- Quantisation 4-bit : 70-80% réduction mémoire
- LoRA : Fine-tuning accessible sur GPU grand public

⚠ Réalité des équipes de cybersécurité

Hardware accessible : RTX 4070 Ti Super (16GB), RTX 4090 (24GB)

Modèles compatibles : Gemma3n 2B et 4B, Phi-4-mini avec LoRA

QLoRA : Fine-tuning de Llama 3.1 8B possible sur GPU grand public !

Exigences VRAM par Modèle et Scénario



QLoRA : 75% réduction VRAM • Llama 3.1 8B accessible sur RTX 4070 Ti Super

Vue d'ensemble des outils : LoRA, Unsloth & Petits modèles

Affinage efficace pour applications cybersécurité

⚡ LoRA (Low-Rank Adaptation)

Principe : Gèle les poids, ajoute petites matrices entraînables.

33% Mémoire

Réduction avec QLoRA

10 000x

Moins de paramètres

- ✓ Adaptateurs compacts (~30MB), fusion facile
- ✓ Perte de précision minimale, inférence 2x plus rapide

🖼 Framework Unsloth

30x Plus Rapide

vs Flash Attention 2

90% Moins

Usage mémoire

Minimum : Entraîne sur seulement 3GB VRAM.

- ✓ Support : LoRA, QLoRA, DPO, ORPO, KTO
- ✓ Compatible : Llama 3.1, Mistral, Gemma 2B et 4B

Comparaison des Modèles pour Cybersécurité

Modèle	Params	Contexte	Mémoire	MMLU	Focus
Gemma 2B	2.51B	8K	~5GB	51.3%	Général
Gemma 4B	4.3B	131K	~9GB	59.6%	Général
Phi-4-mini	3.8B	131K	~8GB	67.3%	Raisonnement
Llama 3.1 8B	8.03B	131K	~16GB	66.7%	Général Pro
Llama-Primus	~8B	8K	~17GB	+15.8%	Cybersécurité

🛡 Llama-Primus : Optimisé pour Cybersécurité

Données d'Entraînement

2,77B tokens spécifiques cyber

Gains de Performance

- Examens CISSP : +1,57%
- Mapping CVE → CWE : +8,7%

Applications

- Intelligence des Menaces
- Évaluation Vulnérabilités

Comparaison Matériel & Performance

RTX 4070 Ti Super vs. Google Colab

🖥 RTX 4070 Ti Super (Config Locale)

Architecture Ada Lovelace	16 GB VRAM
8,448 Cœurs CUDA	2,61 GHz Horloge Boost

Défis

- Goulots CPU & limites VRAM
- Configuration CUDA complexe

Avantages

- ✓ Durée illimitée, pas de timeout
- ✓ Rentable, contrôle total

☁ Options GPU Google Colab

\$ Tesla T4 (Gratuit)

15 GB
VRAM

3,0 min


Options Pro et Pro+ (ex. A100)

Jusqu'à 40 GB VRAM, entraînement significativement plus rapide au coût horaire.

Bénéfices

- ✓ Pré-configuré & intégration facile
- ✓ Disponibilité instantanée, pas d'installation

Performance d'Entraînement (Tâche 100K Époque)



⚡ Recommandations

RTX 4070 Ti Super Pour :

- Développement persistant
- Projets long terme

Colab Pour :

- Expériences rapides
- Besoins VRAM importants

Insight Clé : Colab T4 offre le meilleur équilibre performance/coût.

Collecte de données & Jeux de données Cybersécurité

Préparation structurée pour affinage efficace des LLM

📁 Jeux Structurés

CAPEC : 559 modèles d'attaque

CVE : 73k+ vulnérabilités

CWE : 857 types de faiblesses

CyNER : 13k+ phrases

Applications :

- Identification d'acteurs de menace
- Corrélation vulnérabilités & extraction IoC

Scores F1 SecBERT jusqu'à **64,09%**

🔒 Collections Spécialisées

CyberLLMInstruct

54k+ paires d'instructions (Malware, Phishing)

92,50% précision CyberMetric

Rapports APT MITRE

350 vrais rapports CTI, ~3k mots en moyenne

Défi : Précision LLM à 0,76

Données Entraînement Cybertron Primus

Jeux vérifiés 0,2B & 2,57B tokens

🧠 Données IA-Générées

Classification IoC

GPT-3.5 affiné sur 12k instances

77-82% précision classification

Considérations Qualité :

- Préférer curation manuelle haute-qualité
- Équilibrer classes pour éviter biais

Défis :

- Données étiquetées limitées & restrictions confidentialité

<> Formatage Jeu de Données

```
def format_prompt(ex):  
    # Template pour Analyse IoC  
    prompt = f"""### Instruction:  
Analyser l'IoC suivant :  
### Entrée:  
{ex["ioc_data"]}  
### Réponse:  
{ex["analysis"]}"""  
    return {"text": prompt}
```

Principes Clés : Qualité plutôt que Quantité

Suggestion de modèles

Pour agents de cybersécurité Octobre 2025

Agents Spécialisés (-5B)

Agent	Modèle SLM recommandé	Tâche/précision	Dataset(s) fine-tuning
Détection phishing	Llama 3.2 1B, Qwen2.5 0.5B, Phi-3 Mini	classification emails, URLs, indicateurs	UCI Phishing Websites, Phishing legitimate full, Kaggle Phishing Email
Analyse logs sécurité	SmolLM 1.7B, Qwen2.5 1.5B	parsing, extraction d'événements, priorisation	AI-Enhanced Cybersecurity Events, CyberLLMInstruct
Détection secrets/code	Llama 3.2 1B, TinyLlama	clés/API/secrets dans le code	GitHub secrets datasets
Analyse vulnérabilités/code	Qwen2.5 3B, Gemma 2 2B	détection de vulnérabilités	Devign, Big-Vul, BADS (Code Intent Summary)
CTI/Extraction IOC	SmolLM 1.7B, Qwen2.5 1.5B	extraction entités, fusion, CTI rapport	CyberLLMInstruct, CTI Bench, MITRE ATT&CK JSON
Génération documentation/policy	Gemma 2 2B, TinyLlama	SOP, génération de politiques	Cybersecurity Policy Generator, Internal Audit Datasets
Playbook IR	Llama 3.2 1B, Qwen2.5 1.5B	enrichissement de playbook et réponse	Cyber Incident Response Datasets, AI-Enhanced Cyber Events

Planificateur/Orchestrateur

Raisonnement : PHI-4-mini-reasoning (VRAM bas)
ou GPT-OSS:20B (VRAM élevé)
128K contexte, sécurité, robustesse

Rôle :

Gestion du flow, assemblage des sous-tâches, arbitrage agentique

Magistral-Small-2506 est une alternative pour la compliance, une logique complexe mais requiert une VRAM très élevée

Sautons dans le code!

✓ Tests & Validation du Modèle

Métriques de performance et évaluation pour applications cybersécurité

🎯 Benchmarks Cyber

Examens CISSP

70,73% → 72,30% (+2,2%)

CTI-Bench MCQ

64,20% → 66,76% (+4,0%)

Mapping CVE-CWE

59,10% → 67,80% (+14,7%)

Développez vos propres benchmarks dans votre lab

↗ Indicateurs de Performance Clés

Qualité : Cohérence des réponses, Vérif. Biais

Latence : Tokens/sec, Temps de réponse initiale

Coût : Coût/Tokens, Coût d'inférence

📊 Surveillance Continue


Détection Dérive & Évolution Menaces

Surveillance continue et réentraînement

Tests de Sécurité

- Résistance aux attaques adverses
- Vérifications contenu nuisible

Perte Entraînement & Précision Validation



Implémentation Évaluation

```
def evaluate(model, dataset):  
    correct = 0  
    for item in dataset:  
        inputs = tokenizer(item['prompt'], tensors='pt')  
        outputs = model.generate(**inputs)  
        pred = tokenizer.decode(outputs[0])  
        if pred == item['answer']: correct += 1  
    return {"acc": correct / len(dataset)}
```

✓ Surveiller plateau validation pour éviter sur-apprentissage | ✓ Utiliser métriques domaine-spécifique au-delà précision

Cas d'utilisation en cybersécurité : Applications Terrain

Opérations SOC, Équipes Rouge/Bleue & Analyse Malware

🛡️ Opérations SOC

- **Résumé Alertes** : Réduire bruit alertes.

Threat Intelligence : Extraire IoCs ou mapper vers MITRE ATT&CK.

Réponse Incident : Auto-générer playbooks de réponse.

Désobfuscation Scripts : Analyser code malveillant instantanément.

Convertir des règles Sigma ou Yara ou en générer

🔪 Équipes Rouge & Bleue

- **Équipe Rouge** : Concevoir campagnes d'attaque & générer contenu phishing.

- **Simulation APT** : Automatiser planification mouvement latéral.

- **Équipe Bleue** : Optimiser règles détection & trouver lacunes couverture.

Générer des sommaires rapports

🔍 Analyse Malware

- **Analyse Statique** : Désobfusquer code & interpréter assembleur.

- **Analyse Dynamique** : Classifier comportement depuis rapports sandbox.

- **Intel Menaces** : Corréler IoCs & auto-générer règles YARA.

Faire des meilleurs mapping MITRE

↗️ Métriques de Performance Terrain

98,9%

Précision Détection Malware

40% Réduction

Des Faux Positifs

3x Plus Rapide

Analyse Threat Hunting

75% Amélioration

Temps Moyen de Détection

Facteurs de Succès : Affinage spécifique domaine • Intégration outils sécurité • Validation humain-dans-boucle • Mises à jour modèle continues

Résultats & Leçons apprises

Conclusions clés et recommandations pratiques

✓ Réalisations Clés

30 à 70x Affinage + Rapide
vs. Méthodes Standards

90% Réduction Mémoire
Avec Unsloth & QLoRA

- IA accessible sur matériel grand public
- Rentable pour les petites équipes sécurité

Inférence sur 3GB VRAM
vs. 21GB+ pour Modèle Complet

⚠ Défis Principaux

- Goulots d'étranglement matériel avec GPU grand public (ex. RTX 4070 Ti Super)
- Disponibilité limitée jeux données cybersécurité étiquetées
- Longueur contexte 8K limite analyse complexe multi-étapes
- L'affinage peut réduire résilience sécurité intégrée du modèle
- Potentiel génération contenu nuisible nécessite garde-fous

↗ Ce qui a Bien Fonctionné

- Rang LoRA 8-16 s'est avéré optimal pour tâches cyber
- Taux apprentissage $2e-4$ a fourni convergence stable
- 1-3 epoch suffisantes pour éviter sur-apprentissage
- Données haute-qualité, spécifiques domaine cruciales
- QLoRA est essentiel pour entraînement sur VRAM limitée

💡 Recommandations Pratiques

- Commencer avec Colab T4 ou PRO pour expériences initiales bas-coût
- Se concentrer sur cas d'usage spécifiques, étroits pour meilleurs résultats
- Utiliser QLoRA pour environnements contraints mémoire
- Toujours implémenter validation humain-dans-boucle
- Appliquer couches sécurité additionnelles et tests adverses
- Planifier réentraînement régulier avec nouvelle intelligence menaces

Formule du Succès : Données Qualité + Affinage Efficace + Supervision Humaine = IA Cybersécurité Pratique

Session Q&R & Ressources

Discussion, questions et prochaines étapes

Sujets de Discussion & Questions

Questions Fréquentes :

- Quel cas d'usage convient le mieux à mon environnement SOC ?
- Comment commencer avec un budget limité ?

Domaines de Discussion :

- Défis cybersécurité spécifiques dans votre organisation
- Préoccupations disponibilité et qualité des données

Obtenir Assistance Supplémentaire

Prochaines Étapes & Collaboration :

- Programmer sessions de consultation de suivi
- Rejoindre notre groupe de travail implémentation IA cybersécurité

Ressources Essentielles & Liens

Documentation :

- Guide Unsloth : docs.unsloth.ai/get-started
- LoRA Expliqué : digitalocean.com/community/tutorials

Modèles & Jeux de Données :

- Llama-Primus : huggingface.co/trend-cybertron
- CyberLLMInstruct : 54 928 paires d'instructions

Plan d'Implémentation 30 Jours

Semaine 1 : Config & Définition

Config environnement & exécuter exemples

Semaine 2 : Données & Entraînement

Préparer données & exécuter premier affinage

Semaine 3 : Validation

Évaluer performance modèle sur cas de test

Semaine 4 : Déploiement Pilote

Déployer pilote & recueillir retours utilisateurs

Merci !

Petits LLM + Affinage = IA Cybersécurité Démocratisée



Code et Ressources Pratiques

Accès libre au code source et à la documentation

Scannez pour accéder au code

Ou utilisez le lien ci-dessous



 **Lien Direct GitHub**

`github.com/girdav01/FineTuning-
SmallCyberLLM`

Repos Open Source

Licence MIT • Contributions Bienvenues

< > Contenu du Repository

 **Lien vers la démo**

Vidéo MP4

 **Datasets - Exemples**

Jeux de données cybersécurité formatés.

 **Références Pratiques**

Guides d'installation et bonnes pratiques.

 **Notebooks Jupyter**

Tutoriels interactifs pour Google Colab.

 **Démarrage Rapide** ou **Google Colab**

- | | |
|--|---|
| 1. Cloner le repository | 1. Copier le notebook dans votre google drive |
| 2. Suivre le README.md pour l'installation | 2. Double click pour ouvrir dans Colab |
| 3. Exécuter le premier exemple | 3. Choisir T4 GPU |

Remerciements : Merci à mes collègues de Trend Micro pour leur support depuis 2017 dans cette aventure autour de l'IA pour augmenter la cybersécurité et maintenant sécuriser l'IA. Merci Spark Tsao!

Références

Unsloth example notebooks

[https://colab.research.google.com/github/unslothai/notebooks/blob/main/nb/Gemma3N_\(4B\)-Conversational.ipynb#scrollTo=Mkq4RvEq7FQr](https://colab.research.google.com/github/unslothai/notebooks/blob/main/nb/Gemma3N_(4B)-Conversational.ipynb#scrollTo=Mkq4RvEq7FQr)

Si vous doutez de LoRA un de mes collègue data scientist vous recommande:

[LoRA Without Regret - Thinking Machines Lab](#)

Datasets et Models (Trend Cybertron Primus)

<https://huggingface.co/trend-cybertron>